

**Reconocimiento de Señas Manuales y Planificación Adaptativa para la Retroalimentación
Inmediata y el Registro Objetivo del Aprendizaje de Notas Musicales en Niños de 3 a 12
Años de Montería, Córdoba, 2026**

Equipo XX: [nombres completos de los integrantes]

Facultad de Ingeniería Industrial, Universidad Pontificia Bolivariana, Seccional Montería

8830 0064 0: Gestión Tecnológica

M.Sc. Cristian Javier Cano Mogollón

1 de octubre de 2026

Resumen

En 2024 solo el 47,2 % de los hogares de Córdoba tenía internet, frente al 65,6 % nacional, y en aulas de Montería y Cereté la enseñanza de las notas musicales depende de la atención de un docente a muchos niños, con nivelación manual y sin registro por nota. Hand Sing Kids, HSK, es una aplicación de escritorio que enseña las ocho notas del solfeo, de DO3 a DO4, a niños de 3 a 12 años mediante señas de las manos reconocidas por una cámara, y que procesa todo en el equipo del usuario. El modelo de procesos en BPMN 2.0 contrasta la clase actual con un proceso en que el reconocimiento, el registro y el repaso son automáticos. El prototipo combina un descriptor invariante de 120 componentes, un clasificador por distancia ponderada, un gemelo digital con repaso espaciado y una planificación de sesiones por programación lineal entera mixta. Sobre la calibración de referencia acierta el 100 % sin ruido y el 86,0 % con ruido alto, dispara una nota por error en el 8,0 % de las posturas que no son seña y calcula en 2,3 ms por fotograma. Con insumos rotulados por procedencia, un aula obtiene un retorno de la inversión de 18,9 % en el primer año y la recupera en 63,4 meses; una institución con cuatro aulas, 71,4 % y 16,8 meses. Los supuestos y las constantes pedagógicas aún no se han validado con niños.

Palabras clave: reconocimiento de señas, educación musical, aprendizaje adaptativo, gemelo digital, programación lineal entera mixta, gobernanza de datos

Abstract

In 2024 only 47.2 % of households in Córdoba had internet access, versus 65.6 % nationally, and in classrooms of Montería and Cereté music-note teaching relies on one teacher attending many children, with manual leveling and no per-note record. Hand Sing Kids, HSK, is a desktop application that teaches the eight solfège notes, C3 to C4, to children aged 3 to 12 through hand signs recognized by a camera, processing everything on the user's computer. The BPMN 2.0 process model contrasts the current class with a process where recognition, recording and review are automatic. The prototype combines a 120-component invariant descriptor, a weighted-distance classifier, a learner digital twin with spaced repetition and a session planner formulated as a mixed-integer linear program. On the reference calibration it reaches 100 % accuracy without noise and 86.0 % under high noise, fires a wrong note on 8.0 % of non-sign postures and computes in 2.3 ms per frame. With inputs labeled by provenance, one classroom yields a first-year return on investment of 18.9 % and a payback of 63.4 months; an institution with four classrooms, 71.4 % and 16.8 months. Assumptions and pedagogical constants have not yet been validated with children.

Keywords: sign recognition, music education, adaptive learning, digital twin, mixed-integer linear programming, data governance

Reconocimiento de Señas Manuales y Planificación Adaptativa para la Retroalimentación Inmediata y el Registro Objetivo del Aprendizaje de Notas Musicales en Niños de 3 a 12 Años de Montería, Córdoba, 2026

Hand Sing Kids, HSK, es una aplicación de escritorio que enseña las ocho notas del solfeo, de DO3 a DO4, a niños de 3 a 12 años mediante señas de las manos que una cámara reconoce. Cada seña se convierte en una nota, la nota se evalúa y el resultado modifica la actividad siguiente. Todo el procesamiento ocurre en el equipo del usuario: no se graba video y ningún dato sale hacia servidores externos.


El proyecto se plantea como *Empresa de Base Tecnológica*, EBT, en la asignatura Gestión Tecnológica, GT, de la Universidad Pontificia Bolivariana, Seccional Montería. El documento consolida la ingeniería de detalle del segundo corte: el diagnóstico de la brecha tecnológica, el prototipo funcional mínimo, *Minimum Viable Product*, MVP, el modelado de procesos en *Business Process Model and Notation*, BPMN 2.0, los diagramas de flujo de datos, DFD, la gobernanza de datos y la evaluación financiera. Las cifras técnicas se comprobaron en el código y en pruebas ejecutadas; las financieras dependen de supuestos que se declaran como tales.

Planteamiento del Problema

El aprendizaje de las notas musicales requiere retroalimentación inmediata y repaso a intervalos adecuados. En un aula, el docente atiende a muchos niños a la vez, evalúa de forma manual y no conserva un registro por nota que le permita decidir qué reforzar. La Figura 1 organiza el problema central con sus causas y efectos; una de las causas es la conectividad: en 2024 solo el 47,2 % de los hogares de Córdoba tenía internet, frente al 65,6 % nacional (Departamento Administrativo Nacional de Estadística [DANE], 2025).

Figura 1

Árbol de Problemas de la Enseñanza de Notas Musicales en Niños de Montería



Nota. Elaboración propia. La causa de conectividad proviene de DANE (2025); las de atención y evaluación corresponden al proceso actual modelado en BPMN; la última es la brecha hallada en la revisión de la literatura.

Pregunta de Investigación y Objetivos

La pregunta que orienta el proyecto es: ¿en qué medida un sistema local que reconoce señas manuales y planifica de forma adaptativa la práctica puede ofrecer retroalimentación individual inmediata y un registro objetivo del dominio de las notas musicales en niños de 3 a 12 años de Montería? El objetivo general es *diseñar, construir y verificar técnicamente* un prototipo que reconozca las señas de las ocho notas y adapte la práctica de cada niño, y evaluar su viabilidad financiera. Los objetivos específicos, OE, son:

- OE1: diagnosticar la brecha tecnológica regional con indicadores oficiales y revisar la literatura reciente;
- OE2: construir el prototipo, con reconocimiento de señas, gemelo digital del aprendiz, planificación adaptativa y gobernanza local de los datos;

- OE3: verificar el desempeño técnico del prototipo y estimar el retorno de la inversión con supuestos explícitos.

Justificación

El diseño se orienta a tres Objetivos de Desarrollo Sostenible, ODS: el 4, educación de calidad, por la práctica individual con seguimiento; el 9, industria, innovación e infraestructura, por tratarse de tecnología que funciona sin nube en un territorio con conectividad desigual; y el 10, reducción de las desigualdades, porque solo requiere un computador y una cámara web. Se trata de una orientación del diseño, no de un impacto medido.

Diagnóstico y Brecha Tecnológica

Fuentes y Método

Los indicadores provienen del boletín técnico de la Encuesta de Tecnologías de la Información y las Comunicaciones en Hogares, ENTIC Hogares, 2024 (DANE, 2025). Los valores nacionales figuran en el texto del boletín y los de Córdoba se leyeron de sus gráficos departamentales. La población de Montería se tomó del archivo oficial de proyecciones municipales por edad simple, actualización posterior a la COVID-19 (DANE, s. f.). La caracterización de aulas proviene de un estudio previo del mismo proyecto (Equipo 13, 2026), tratado como fuente secundaria no verificada.

Indicadores Regionales

La Tabla 1 compara Córdoba con el total nacional. La brecha más amplia es la de hogares con internet, 18,4 puntos porcentuales: en 52,8 de cada 100 hogares del departamento no hay conexión, de modo que una solución que dependa de la nube excluye a más de la mitad de ellos.

Tabla 1*Acceso a Tecnologías de la Información en Córdoba y en el Total Nacional, 2024*

Indicador	Córdoba	Nacional	Diferencia (p. p.)
Hogares con conexión a internet	47,2 %	65,6 %	−18,4
Personas que usaron computador	25,2 %	35,1 %	−9,9
Personas de 5 años o más que usaron internet	71,9 %	79,3 %	−7,4
Hogares con computador	Sin dato	35,7 %	—

Nota. Datos de DANE (2025), gráficos 2, 6, 13 y 15. p. p. = puntos porcentuales. En el total nacional, el 72,5 % de los hogares de las cabeceras tenía internet, frente al 41,9 % de los centros poblados y el área rural dispersa.

Población Objetivo

La proyección oficial para Montería en 2026 es de 535.052 habitantes, de los cuales 80.254 tienen entre 3 y 12 años, el 15,0 % del municipio (22.595 de 3 a 5 años, 24.406 de 6 a 8 y 33.253 de 9 a 12; DANE, s. f.). Esta cifra acota el universo potencial, pero no es la demanda: el número de aulas de música de la ciudad y su matrícula no se encontraron en fuentes oficiales, por lo que el modelo financiero parte de un aula.

Caracterización de Campo

El Equipo 13 (2026) reporta observaciones en aulas de instituciones de Montería y Cereté, con un recorrido de campo adaptado del *Gemba Walk* (Tabla 2). El estudio no documenta el tamaño de la muestra ni los instrumentos, por lo que sus cifras se usan para dimensionar el modelo financiero y no para sostener conclusiones sobre el efecto del sistema.

Tabla 2*Caracterización de Aulas de Montería y Cereté según el Estudio Previo*

Observación	Cifra reportada	Uso en este documento
Nivelación individual: preparación manual de fichas y partituras	1,0 a 1,5 h por semana	Beneficio 1 (se usa 1,0 h)
Papelería: fotocopias y cuadernos de pentagrama	\$ 600.000 por aula y año	Beneficio 2
Niños con teclado o xilófono propio en el aula	Menos del 15 %	Contexto
Tiempo de clase en explicación teórica	60 % a 70 %	Proceso actual
Pérdida de atención en lectura teórica pasiva	A los 10 a 12 min	Duración de la sesión
Abandono en el primer semestre	Superior al 55 %	Contexto
Línea base del grupo de control: discriminación de notas; respuesta motriz; retención a cuatro semanas	42,91 ± 7,56 sobre 100; 5,48 ± 0,92 s; menos del 40 %	Referencia del piloto

Nota. Datos de Equipo 13 (2026), no verificados de forma independiente.

Brecha Tecnológica

La *brecha tecnológica* se entiende como la distancia entre lo que requiere la práctica musical infantil y lo que el contexto regional permite sostener. Tiene tres componentes medibles: conectividad, por la diferencia de 18,4 puntos en hogares con internet; equipamiento, porque solo el 25,2 % de las personas de Córdoba usó un computador en 2024; y proceso, porque la evaluación en el aula es manual y no deja registro por nota. El prototipo responde con procesamiento local, requisitos de hardware mínimos (computador y cámara web) y registro automático de cada intento.

Revisión de la Literatura

La búsqueda partió de la matriz bibliográfica del proyecto, con 189 documentos únicos clasificados por su relación con el sistema. Se seleccionaron 15 artículos de relación alta o media, publicados entre 2023 y 2026, con DOI. Cada DOI se contrastó con la interfaz de Crossref (título, año, autores y revista) y se comprobó que resuelve en doi.org; la verificación se repitió el 1 de octubre de 2026. Un artículo sobre la postura en la interpretación del guzheng se excluyó porque Crossref lo registra con una nota editorial de preocupación. La Tabla 3 resume el conjunto.

Tabla 3

Estudios Revisados, Aporte al Proyecto y Límite frente a HSK

Estudio	Aporte	Límite frente a HSK
Yi et al., 2024	Revisión de tecnologías de inteligencia artificial en educación infantil temprana.	Panorama general; no trata señas ni música.
Apaydinli, 2023	Análisis de contenido de estudios de realidad aumentada en educación musical.	Requiere instrumento o dispositivo de realidad aumentada.
Mazlan et al., 2023	Revisión del aprendizaje en porciones breves; respalda actividades cortas.	Revisión conceptual, sin niños.
Barroso-Osuna et al., 2024	Experimento con 234 estudiantes sobre apps móviles y carga de trabajo en educación musical.	Universitarios; sin reconocimiento de gestos.
León-Garrido et al., 2024	Instrumento validado por expertos para evaluar apps musicales.	No cubre visión artificial.
Li y Hong, 2026	Rutas de aprendizaje musical con aprendizaje por refuerzo profundo.	Requiere mucho entrenamiento; poco interpretable.
Li, 2026	Evaluación adaptativa basada en aprendizaje por refuerzo.	Sin entrada por señas ni procesamiento local.

Estudio	Aporte	Límite frente a HSK
Li, 2026	Planificación de rutas de aprendizaje con red neuronal profunda.	Necesita muchos datos por alumno.
Deng et al., 2026	Sistema adaptativo sensible a emociones.	Entrada afectiva, no gestual.
Shi, 2026	Computación afectiva en educación musical preescolar (120 niños).	Infraestructura de cómputo pesada.
Deng, 2026	Retroalimentación con IA en piano (240 estudiantes).	Universitarios; requiere piano.
Chuluunsaikhan y Park, 2026	Detección del teclado de piano en video con aprendizaje profundo.	La entrada es un instrumento, no señas.
Tang, 2026	Interacción adaptativa en la enseñanza musical con refuerzo profundo.	Sin entrada gestual.
Wang, 2026	Evaluación multimodal de la enseñanza musical (audio, video y texto).	Arquitectura dependiente de servicios.
Ramonedá et al., 2026	Generación de ejercicios de lectura ajustados a la dificultad.	Piano y partitura.

Nota. Síntesis elaborada a partir de los resúmenes y metadatos de cada artículo, no del texto completo. IA = inteligencia artificial.

Brecha de Investigación

En el conjunto revisado predominan propuestas que adaptan la enseñanza con modelos profundos o de refuerzo, sobre poblaciones universitarias o de piano, y con entradas como audio, video de un instrumento o señales afectivas. *No se identificó* un sistema que combine entrada por señas manuales para nombrar notas, población de 3 a 12 años, procesamiento local y planificación adaptativa interpretable; esa combinación es la brecha que aborda HSK. La afirmación se limita a los 15 estudios y no sustituye una revisión sistemática. De la literatura se adoptan actividades breves (Mazlan et al., 2023), una dificultad objetivo intermedia (Ramonedá et al., 2026) y una planificación explícita en lugar del refuerzo profundo (Li y Hong, 2026; Tang, 2026), cuya necesidad de datos no se ajusta a un niño que genera pocos intentos por sesión.

Método

El trabajo sigue la estructura de introducción, método, resultados y discusión, IMRyD, adaptada a un proyecto de ingeniería: el método es un ciclo de diseño, construcción y verificación, y los resultados son mediciones reproducibles sobre el prototipo. Cada cifra se clasificó como verificada en el código, verificada con una prueba ejecutada, tomada de una

fuentes oficiales o supuestas; los documentos previos del proyecto que contradecían el código se corrigieron a favor de este.

Las fases fueron cinco: diagnóstico, con los indicadores del DANE, la caracterización de campo y el proceso As-Is (Tabla 1; Tabla 2; Figura 4); revisión, con la selección de 15 estudios y la verificación de sus DOI (Tabla 3); diseño y construcción, en Python con PySide6, MediaPipe, OpenCV, NumPy, PuLP y SQLite (10.581 líneas de código y 1.746 de pruebas; Figura 2); verificación, con pruebas automáticas, medición de latencia y auditoría de integridad de datos (Tabla 4; Tabla 5; Tabla 10); y evaluación financiera, con CAPEX, OPEX, beneficios, ROI y periodo de recuperación (Tabla 14; Tabla 15).

Arquitectura de Gestión Tecnológica y Prototipo

Arquitectura en Capas


El sistema se organiza en cinco capas que solo dependen de las inferiores (Figura 2), y un bus de eventos permite que las superiores reaccionen sin acoplarse. Ninguna pantalla importa MediaPipe, ningún componente de visión conoce las notas musicales y el evaluador no dibuja; esa separación permite ejecutar las pruebas sin cámara y sin ventana.

Reconocimiento de Señas

La versión 1 concatenaba las coordenadas de ambas manos (126 componentes) y aceptaba la señal más parecida por similitud coseno si superaba 0,65; sobre la calibración real, ese criterio disparaba una nota en el 100 % de las posturas que no eran seña. La versión 2.0 usa un descriptor geométrico invariante. Sean $p_0, \dots, p_{20} \in \mathbb{R}^3$ los 21 puntos que entrega *MediaPipe Hands* para una mano (Zhang et al., 2020); la escala σ es la distancia de la muñeca al nudillo medio y la curvatura κ de cada dedo, con articulaciones (a, b, c, d), es una razón de longitudes, invariante a escala, traslación y rotación:

$$\sigma = \|p_9 - p_0\|, \quad \kappa = \text{clip}(\|p_d - p_a\| / (\|p_b - p_a\| + \|p_c - p_b\| + \|p_d - p_c\|) - 0,35) / 0,65, \quad (1)$$

$0, 1)$

Figura 2*Arquitectura en Cinco Capas de HandSingKids7*

Nota. Nombres de módulos tomados del paquete *handsingkids* de la versión 2.0.

Cada mano aporta 58 valores (curvatura, apertura entre dedos, distancias del pulgar, normal de la palma, dirección y forma normalizada) y con las dos manos se añaden 4 magnitudes relativas: el descriptor tiene 120 componentes. La comparación es una distancia ponderada por bloques g , y la confianza se reparte con una función *softmax* cuya temperatura T se ajusta a la separación entre las señas del niño:

$$d(a,b) = \sqrt[4]{(\sum_g w_g \cdot (1/|g|) \sum_{i \in g} (a_i - b_i)^2 / \sum_g w_g)} \quad (2)$$

$$P(c | x) = \exp(-(d_c - d_{min})/T) / \sum_k \exp(-(d_k - d_{min})/T), \quad T = \text{clip}(\frac{1}{2} \cdot \min_{a \neq b} d(a,b), 0,05, 0,20) \quad (3)$$

Una seña se acepta si $d_{\text{mejor}} \leq 0,95$, $P_{\text{mejor}} \geq 0,55$ y $P_{\text{mejor}} - P_{\text{segunda}} \geq 0,08$; la tercera condición evita decidir entre dos señas empatadas. Un estabilizador temporal exige 0,45 s entre confirmaciones y, para repetir la misma nota, que la mano se suelte durante 6 fotogramas; la cámara opera a 24 fotogramas por segundo. La Tabla 4 muestra el efecto: el método nuevo cede algo de sensibilidad con ruido alto porque se abstiene, y a cambio rechaza 92 de cada 100 posturas que no son seña.

Tabla 4

Desempeño del Reconocimiento sobre la Calibración Real con Escala, Giro y Ruido Simulados

Condición	Versión 2.0	Versión 1
Señas válidas, ruido $\sigma = 0,00$	100,0 %	100,0 %
Señas válidas, ruido $\sigma = 0,03$	100,0 %	100,0 %
Señas válidas, ruido $\sigma = 0,06$	96,9 %	100,0 %
Señas válidas, ruido $\sigma = 0,09$	86,0 %	100,0 %
Posturas que no son seña (n = 640): notas disparadas por error	8,0 %	100,0 %

Nota. Resultados de `tests/test_vision.py`: escala entre 0,8 y 1,25, giro de $\pm 18^\circ$ por mano y ruido gaussiano proporcional al tamaño de la mano. La calibración es de una sola persona, por lo que la muestra es limitada.

El descriptor y el clasificador tardan en promedio 2,3 ms por fotograma (percentil 95: 4,8 ms; 1.000 fotogramas). La medición excluye la captura de la cámara y la inferencia de MediaPipe, por lo que no es la latencia de extremo a extremo, que no se ha medido.

Gemelo Digital y Repaso Espaciado

El *gemelo digital* del aprendiz es su estado de aprendizaje por habilidad: dominio, precisión, consistencia, velocidad, retención y próximo repaso. El dominio M_s no es una suma: la retención R_s multiplica al desempeño, de modo que una habilidad sin práctica pierde dominio.

Con $\lambda = 0,65$, $\gamma = 0,40$, $w_p = 0,55$, $w_c = 0,25$ y $w_v = 0,20$:

$$M_s = (\lambda + (1 - \lambda) R_s^\gamma) \cdot (w_p P_s + w_c C_s + w_v V_s), \quad R_s = \exp(-\Delta t / \tau_s) \quad (4)$$

La precisión usa suavizado bayesiano, $P_s = (\text{aciertos} + 1) / (\text{intentos} + 4)$; la velocidad se normaliza con un tiempo de referencia por edad (5.200, 4.000 y 3.200 ms para 3 a 5, 6 a 8 y 9 a 12 años). Una habilidad se considera dominada con $M_s \geq 0,80$ y al menos seis intentos. El repaso

adapta el algoritmo SM-2 a una calidad continua: si la precisión de la actividad es menor que 0,6, el intervalo vuelve a un día.

Motor Adaptativo y Planificación de la Sesión


El motor adaptativo aplica reglas explícitas en orden: descanso si la fatiga $F \geq 1$; ayuda escalonada si hay fallos consecutivos y la precisión es menor que 55 %; juego si $F \geq 0,7$; repaso si hay repasos vencidos; subida de dificultad si la precisión llega a 88 %; y, en otro caso, refuerzo o mantenimiento. La selección de actividades de la sesión es el único componente formulado como problema de optimización: un programa lineal entero mixto, MILP, que maximiza la ganancia de aprendizaje g_i , la urgencia de repaso r_i y la motivación m_i y penaliza la fatiga f_i :

$$\max \sum_{i \in A} (1,00 g_i + 0,70 r_i + 0,35 m_i - 0,55 f_i) x_i, \quad x_i \in \{0, 1\} \quad (5)$$

Las restricciones son siete: tiempo total, número exacto de actividades, prerrequisitos, al menos una actividad lúdica, dificultad media menor o igual a 0,72, no más de dos actividades por habilidad y al menos un repaso vencido si existe. La probabilidad de éxito de cada actividad la estima una función logística que, con 40 intentos o más del niño, se reajusta por regresión logística sobre sus propios datos. El problema se resuelve con el solucionador CBC mediante PuLP en 0,15 a 1,8 s por sesión con 24 candidatas, y una enumeración exhaustiva devolvió el mismo óptimo; las constantes provienen de la literatura y de decisiones de diseño, no de un estudio con niños.

Estado Funcional del Prototipo

La versión 2.0 tiene 14 pantallas: bienvenida, perfiles, creación de perfil, inicio, mapa de aventura con 7 niveles, calibración, progreso, Zona de Padres, ajustes, modo libre, ejercicio, resultados, canciones y ritmo (Figura 3). El catálogo incluye 14 habilidades, 63 actividades y 17 logros, con estrellas, monedas y racha de días como elementos de *gamificación*. Las 8 suites de pruebas pasan; una de ellas solo en ejecución individual (Tabla 5). El nivel de madurez tecnológica, *Technology Readiness Level*, TRL, es 4: componentes validados en laboratorio, sin pruebas con niños.

Figura 3*Mapa de Aventura (Izquierda) y Ejercicio Guiado (Derecha)*

Nota. Capturas de la versión 2.0 con un perfil de prueba. En el ejercicio, el fondo es un cuadro de prueba y los esqueletos son los 21 puntos por mano del detector.

Tabla 5*Suites de Pruebas Automáticas y Resultado de su Ejecución*

Archivo	Qué comprueba	Resultado
<i>test_vision.py</i>	Identidad, invariancia a escala y giro; comparación cuantitativa con el método de la versión 1	Pasó
<i>test_stabilizer.py</i>	Sin ráfagas con la mano quieta; transiciones sin notas intermedias; repetición tras soltar	Pasó (8 verificaciones «ok»)
<i>test_mastery.py</i>	Una sesión perfecta no basta para dominar; el intervalo de reposo crece y se reinicia; el olvido degrada	Pasó (8 verificaciones «ok»)
<i>test_optimizer.py</i>	Restricciones del MILP, coincidencia MILP y enumeración, cambio de selección con el perfil	Pasó (8 verificaciones «ok»)
<i>test_predictor.py</i>	Ajuste logístico mejor que el azar, monotonía, serialización y generador procedural	Pasó (27 verificaciones «ok»)
<i>test_rhythm.py</i>	Planificación de tiempos y ventanas del módulo de ritmo	Pasó (28 verificaciones «ok»); cierre anómalo del proceso (código 0xc0000409)
<i>test_audio.py</i>	Capas de sonido (personalizado, incluido, sintetizado) y música de fondo	Pasó (36 verificaciones «ok»)
<i>test_integracion.py</i>	Flujo completo de una sesión con la aplicación real sin ventana visible	Pasó en ejecución individual (8,7 s); en la ejecución en lote se agotó el límite de 600 s

Nota. Ejecución del 1 de octubre de 2026 en Windows 11 (Python 3.12.10, NumPy 1.26.4, PySide6 6.11.2, PuLP 2.9.0, OpenCV 4.11.0, MediaPipe 0.10.21), con la interfaz gráfica en modo offscreen.

Trazabilidad con los Objetivos

Tabla 6

Trazabilidad entre Objetivos Específicos, Componentes y Estado

Objetivo	Componente o evidencia	Estado
OE1	Indicadores del DANE; 15 estudios con DOI verificado	Cumplido; caracterización de campo secundaria
OE2	Visión, gemelo digital, repaso espaciado, planificador MILP, 14 pantallas, base SQLite local	Funcional en banco de pruebas (TRL 4)
OE2	Gobernanza: 11 tablas, sin imágenes en disco ni red	Parcial: 4 de 8 reglas de integridad impuestas
OE3	Banco de reconocimiento; 2,3 ms por fotograma; equivalencia MILP	Cumplido en banco, sin niños
OE3	Modelo financiero con seis escenarios y supuestos rotulados	Cumplido; supuestos por validar en un piloto


Modelado de Procesos de Negocio en BPMN 2.0

El proceso modelado es la enseñanza de una nota y el seguimiento de su aprendizaje. Los diagramas usan *pools* por participante y *swimlanes* por rol; compuertas exclusivas (X), paralelas (+) e inclusivas (O) con sus condiciones rotuladas; eventos de inicio, intermedios de temporizador y de mensaje, y de fin; flujos de secuencia con línea continua y flujos de mensaje con línea punteada. El modelo *As-Is* (Figura 4) describe la clase habitual según la caracterización de campo; el *To-Be* (Figura 5) se construyó a partir del código del prototipo.

En el *To-Be*, la compuerta paralela refleja que el sonido y el dibujo de la nota no esperan a la evaluación, y la inclusiva activa siempre la actualización del dominio y, según el caso, las estrellas y la apertura de habilidades. El temporizador de un fotograma (unos 42 ms a 24 fotogramas por segundo) sustituye la espera de la corrección individual. La Tabla 7, después de las figuras, contrasta ambos procesos punto por punto; las capacidades del *To-Be* están verificadas en el prototipo, pero su efecto en el aula debe medirse en un piloto.

Figura 4


Proceso Actual (As-Is): Enseñanza de una Nota en el Aula de Música



Nota. Marcas rojas: (1) actividad manual con sobrecosto, nivelación de 1,0 a 1,5 h semanales y \$ 600.000 anuales de papelería por aula (Equipo 13, 2026); (2) cuello de botella, atención de uno a muchos; (3) reproceso, la demostración se repite sin diagnóstico del error; (4) registro manual no agregable; (5) redundancia y retraso, el avance anotado se vuelve a comunicar de forma verbal; (6) tiempo muerto, el olvido entre clases no se mide ni se programa.

Figura 5

Proceso Propuesto (To-Be): Sesión de Práctica con Hand Sing Kids



Nota. Tareas amarillas: ejecutadas por el sistema. F = fatiga; d, P y margen = distancia, probabilidad y margen del clasificador. Los intentos se guardan al cerrar cada actividad.

Tabla 7*Cuellos de Botella del Proceso Actual y su Tratamiento en el Proceso Propuesto*


Problema (As-Is)	Evidencia de campo	Capacidad del To-Be	Indicador del piloto
1 Nivelación manual	1,0 a 1,5 h por semana; \$ 600.000 de papelería al año	Planificación automática de la sesión (MILP) y material en pantalla	Horas de nivelación; gasto de papelería
2 Atención de uno a muchos	Respuesta motriz de referencia: 5,48 s	Reconocimiento en cada fotograma (2,3 ms de cómputo)	Tiempo de respuesta
3 Reproceso sin diagnóstico	Se repite la demostración	Matriz de confusiones por nota y ayuda escalonada	Intentos hasta el acierto
4 Registro manual	Cuaderno del docente	Cada intento se guarda con nota esperada, detectada, confianza y reacción	Intentos registrados (verificado: 100 %)
5 Informe tardío	Verbal o por mensaje	Zona de Padres bajo demanda	Consultas por semana
6 Sin repaso programado	Retención inferior al 40 % a cuatro semanas	Repaso espaciado con fecha por habilidad	Retención a cuatro semanas

Nota. Evidencia de campo de Equipo 13 (2026), no verificada.

Diagramas de Flujo de Datos


Los diagramas siguen la notación de Yourdon y DeMarco: círculos para procesos, rectángulos para entidades externas, rectángulos abiertos para almacenes de datos y flechas rotuladas para los flujos. El nivel 0 (Figura 6) delimita el sistema; el nivel 1 (Figura 7) lo descompone en siete procesos; y el nivel 2 (Figura 8) detalla el proceso crítico, la planificación adaptativa, que concentra el procesamiento algorítmico y la mayoría de lecturas de almacenes. Los almacenes D1 a D6 son tablas o archivos reales (véase Gobernanza de Datos).

Figura 6
DFD Nivel 0: Diagrama de Contexto



Nota. Sin entidades externas en la nube.


El *balanceo* exige que los flujos que cruzan la frontera de un proceso reaparezcan en su descomposición. La Tabla 8, a continuación de los diagramas, lo comprueba: los cinco flujos del nivel 0 se reparten sin pérdida ni adición en el nivel 1, y los siete flujos de la frontera del proceso 5.0 reaparecen con el mismo nombre en el nivel 2.

Figura 7*DFD Nivel 1: Descomposición en Siete Procesos*

Nota. D4 aparece dos veces por legibilidad; la línea vertical adicional marca la copia.

Figura 8

DFD Nivel 2: Explosión del Proceso 5.0, Planificar la Sesión Adaptativa



Nota. En gris, los procesos y almacenes vecinos del nivel 1; el proceso 6.0 se dibuja a ambos lados por legibilidad.

Tabla 8
Comprobación del Balanceo entre Niveles

Flujo en el nivel padre	Flujos en el nivel hijo
<i>Nivel 0 → Nivel 1</i>	
Niño → 0: Selección de perfil y de actividad	Niño → 1.0: Selección de perfil; Niño → 6.0: Elección de actividad
0 → Niño: Actividad, nota sonora y resultado	6.0 → Niño: Actividad, nota sonora y resultado
Cámara → 0: Fotogramas RGB	Cámara → 2.0: Fotogramas RGB
Acudiente → 0: Perfil, ajustes y solicitud de informe	Acudiente → 1.0: Perfil y ajustes; Acudiente → 7.0: Solicitud de informe
0 → Acudiente: Informe de progreso	7.0 → Acudiente: Informe de progreso
<i>Nivel 1 → Nivel 2 (proceso 5.0)</i>	
1.0 → 5.0: Perfil, edad y tiempo de sesión	1.0 → 5.1
6.0 → 5.0: Actividad elegida y tiempo jugado	6.0 → 5.1
D4 → 5.0: Estado por habilidad	D4 → 5.1
D6 → 5.0: Modelo de éxito	D6 → 5.3
D5 → 5.0: Actividades y habilidades	D5 → 5.4
5.0 → 6.0: Ruta del día y decisión adaptativa	5.2 → 6.0: Decisión adaptativa; 5.5 → 6.0: Ruta del día
5.0 → 3.0: Actividad y secuencia esperada	5.5 → 3.0

Gobernanza de Datos

El marco toma como referencia el cuerpo de conocimiento DAMA-DMBOK (DAMA International, 2017) en sus áreas de modelado, calidad, metadatos y seguridad. En todo el apartado se distingue lo que el código *impones hoy* de lo que es *política objetivo* aún no implementada. Los principios son tres: privacidad por diseño, porque ningún fotograma se escribe en disco y el paquete no importa módulos de red; soberanía de los datos, porque no hay cuentas ni nube; y calidad medible, porque cada dimensión tiene un procedimiento de comprobación.

Catálogo y Diccionario de Datos

El repositorio es SQLite, con 11 tablas y 97 campos, registro anticipado de escritura (*write-ahead logging*, WAL) y llaves foráneas activas. El diccionario de la Tabla 9 se extrajo del esquema real con las instrucciones PRAGMA de SQLite, de modo que no puede diferir del código. Fuera de la base hay dos almacenes de archivos JSON: las plantillas de calibración y las

melodías grabadas en el modo libre. Los almacenes de los DFD corresponden así: D1, profiles, rewards y profile_achievements; D2, plantillas de cada perfil; D3, sessions, attempts y activity_results; D4, skill_state; D5, skills, activities y achievements; y D6, la fila del predictor en meta.

Tabla 9
Diccionario de Datos del Esquema SQLite

Entidad	Atributos (tipo)	Cardinalidad	Reglas de validación
<i>profiles</i>	id (integer, PK), name (text), age (integer), avatar (text), created_at (real), last_seen_at (real), stars (integer), coins (integer), streak_days (integer), last_play_date (text), calibrated (integer)	Raíz: 1 a N con las tablas del perfil	Nombre de 2 a 18 caracteres y edad de 3 a 12 (interfaz); calibrated en {0, 1}
<i>skills</i>	code (text, PK), name (text), note_code (text, nulo), level (integer), difficulty (real), prerequisites (text), order_index (integer), description (text)	1 a N con skill_state	Dificultad en [0, 1]; prerequisites como lista JSON
<i>skill_state</i>	profile_id (integer, PK), skill_code (text, PK), status (text), mastery (real), precision_v (real), consistency (real), speed (real), retention (real), attempts (integer), hits (integer), mean_reaction_ms (real), last_practice_at (real), due_at (real), ease (real), interval_days (real)	Llave (profile_id, skill_code); N a 1 con profiles y skills	Estado en {bloqueada, introducida, en practica, dominada, consolidada}; dominio, precisión, consistencia, velocidad y retención en [0, 1]
<i>activities</i>	code (text, PK), kind (text), title (text), level (integer), difficulty (real), skill_codes (text), sequence (text), mode (text), tempo_bpm (integer), duration_s (integer), hints (integer), repetitions (integer), description (text), icon (text), tolerance_ms (integer)	Referida por código desde attempts y activity_results	Tipo en {ejercicio, juego, cancion, evaluacion, repaso}; dificultad en [0, 1]
<i>sessions</i>	id (integer, PK), profile_id (integer), started_at (real), ended_at (real, nulo), activities_done (integer), accuracy (real)	N a 1 con profiles; 1 a N con attempts y activity_results	ended_at nulo mientras la sesión está abierta; precisión en [0, 100]
<i>attempts</i>	id (integer, PK), profile_id (integer), session_id (integer, nulo), activity_code (text), step_index (integer), expected (text), detected (text, nulo), confidence (real), correct (integer), reaction_ms (integer), attempt_number (integer), at (real)	N a 1 con profiles (cascada) y sessions (nulo al borrar)	correct en {0, 1}; confianza en [0, 1]; detected nulo si se agotó el tiempo
<i>activity_results</i>	id (integer, PK), profile_id (integer), session_id (integer, nulo), activity_code (text), accuracy (real), rhythm (real), gesture_quality (real), stars (integer), score (integer), max_combo (integer), duration_s (real), steps_total (integer), steps_correct (integer), at (real)	N a 1 con profiles (cascada) y sessions (nulo al borrar)	Estrellas de 1 a 3 (3 si la precisión llega a 90 %; 2 si llega a 70 %)
<i>rewards</i>	id (integer, PK), profile_id (integer), kind (text), code (text), label (text), icon (text), at (real)	N a 1 con profiles (cascada)	Una fila por recompensa otorgada

Entidad	Atributos (tipo)	Cardinalidad	Reglas de validación
<i>achievements</i>	code (text, PK), title (text), description (text), icon (text)	1 a N con profile_achievements	Catálogo fijo de 17 logros
<i>profile_achievements</i>	profile_id (integer, PK), code (text, PK), at (real)	N a 1 con profiles y achievements (cascada)	Un logro por perfil una sola vez (llave compuesta)
<i>meta</i>	key (text, PK), value (text)	Clave y valor, sin relaciones	Valor JSON; una fila de predictor por perfil


Nota. PK = llave primaria; «nulo» = admite valores nulos; los demás campos son NOT NULL. Las reglas de validación las aplican la interfaz y el código de dominio: el esquema no tiene restricciones CHECK.

Linaje del Dato

El linaje (Figura 9) sigue el dato desde la cámara hasta las decisiones: las etapas 1 a 3 existen solo en la memoria del proceso, las etapas 4 y 5 en la memoria de la sesión, y desde el cierre de cada actividad el dato es persistente. El planificador y la Zona de Padres, donde el acudiente o el docente decide qué reforzar, consumen el estado persistente.

Figura 9

Linaje del Dato, de la Cámara a la Toma de Decisiones



Nota. Borde punteado: dato efímero, solo en RAM; amarillo claro: dato de sesión; amarillo: dato persistente en el disco local. Ningún fotograma se escribe en disco. Elaboración propia a partir del código.

Dimensiones de Calidad

Tabla 10

Dimensiones de Calidad, Indicador, Umbral y Resultado

Dimensión	Indicador	Umbral	Resultado
Compleitud	1 – nulos / esperados en campos críticos	100 %	Cumple: NOT NULL impuesto (prueba Q3)
Exactitud	Acierto del reconocimiento con ruido $\sigma = 0,06$	≥ 96 %	Cumple: 96,9 % (Tabla 4)
Consistencia	Integridad referencial y rangos de dominio	100 %	Parcial: llaves foráneas y cascada impuestas (Q2, Q7); la base acepta edad 99, confianza 5,0 y dominio -3 (Q4 a Q6)
Oportunidad	Tiempo entre el cierre de la actividad y la actualización del gemelo	En la misma sesión	Cumple por diseño (escritura síncrona); la latencia de escritura no se midió

Nota. Pruebas Q1 a Q8 de *auditoria_calidad.py* sobre la clase Database real: 4 de 8 reglas impuestas por la base.

Seguridad y Privacidad

Hoy los datos se guardan en la carpeta de datos del usuario del sistema operativo, sin cifrado propio, y la Zona de Padres se abre con un botón: el control de acceso basado en roles, *role-based access control*, RBAC, de la Tabla 11 es por ahora una convención de la interfaz. La Ley Estatutaria 1581 de 2012 contiene reglas especiales para el tratamiento de datos de niños, niñas y adolescentes (Congreso de la República de Colombia, 2012); el procesamiento local reduce la exposición, pero no exime a la institución de obtener la autorización de los representantes, y por ello el CAPEX incluye una consulta jurídica.

Tabla 11

Roles y Permisos (RBAC): Estado Actual y Control Propuesto

Rol	Permisos	Autenticación o mecanismo	Estado
Niño o niña	Jugar, calibrar y ver su progreso	Interfaz infantil	Sin barrera hacia Ajustes ni Zona de Padres
Acudiente o docente	Crear y borrar perfiles, leer informes, cambiar ajustes	Número de identificación personal, PIN, de 4 dígitos guardado con <i>hash</i> y sal (propuesto)	Pendiente
Motor analítico	Escribir intentos y estado; leer y escribir el modelo	Código de la aplicación	Implementado
Cámara	Entregar fotogramas al detector	Proceso de la aplicación, sin persistencia	Implementado

Tabla 12*Políticas de Respaldo, Retención, Eliminación y Confidencialidad*

Política	Regla objetivo	Estado
Respaldo	Copia con la interfaz de respaldo en línea de SQLite al iniciar sesión si hay más de 20 intentos nuevos; se conservan las 3 últimas	No implementado
Retención	Detalle de los últimos 180 días y siempre los últimos 200 intentos de cada niño, que el predictor necesita	No implementado
Eliminación	Al borrar un perfil, borrar sus filas (ya ocurre por cascada), su plantilla, sus melodías y las copias que lo contengan	Parcial (Q7, Q8)
Integridad	Migración con 16 restricciones CHECK, probada sin romper las suites de integración y del predictor	Probada, no aplicada
Confidencialidad	Carpeta accesible solo por el usuario del sistema; cifrado de la base en reposo como opción	Heredado del sistema

Nota. Los parámetros (20 intentos, 3 copias, 180 días y 200 intentos) son propuestas de diseño.

Viabilidad Financiera

El modelo sigue la guía del curso: el beneficio neto anual es el beneficio bruto menos los costos operativos, OPEX; el retorno sobre la inversión, ROI, es el cociente entre ese beneficio y la inversión inicial, CAPEX; y el periodo de recuperación, *payback*, es el CAPEX dividido por el beneficio neto mensual:

$$ROI = (Beneficio\ neto\ anual / CAPEX) \times 100\%, \quad Payback\ (meses) = CAPEX / (Beneficio\ neto\ anual / 12) \quad (6)$$

La unidad de análisis es un aula de música, porque los datos de campo se reportan por aula. Cada insumo tiene una procedencia rotulada en la hoja de cálculo: la tarifa de ingeniería viene de la guía (\$ 25.000 a \$ 40.000 por hora); los valores marcados PINT2 vienen del estudio del Equipo 13 (2026), no verificado; los verificables se comprobaron en el código (no hay nube, interfaz de IA ni red); y los supuestos son estimaciones propias (Tabla 13).

Tabla 13*CAPEX, OPEX y Beneficios de un Aula, con Detalle y Procedencia*

Rubro	Concepto	Detalle	Procedencia	Valor (COP)
CAPEX	Horas de ingeniería y desarrollo	120 h (PINT2) + 80 h de este corte (supuesto) $\times$ \$ 30.000	PINT2, supuesto	\$ 6.000.000
CAPEX	Cámara web, periféricos y soportes	Cámara 720p, periféricos y soportes	PINT2	\$ 450.000
CAPEX	Licenciamiento y configuración inicial	Software de código abierto; puesta a punto	PINT2	\$ 200.000

Rubro	Concepto	Detalle	Procedencia	Valor (COP)
CAPEX	Capacitación a docentes	4 h × \$ 30.000	PINT2	\$ 120.000
CAPEX	Consulta jurídica de protección de datos	Ley 1581 de 2012, datos de menores	Supuesto	\$ 600.000
	Total CAPEX			\$ 7.370.000
OPEX anual	Mantenimiento y soporte técnico	Corrección de errores y librerías	PINT2	\$ 300.000
OPEX anual	Reposición de hardware	10 % anual del hardware	Supuesto	\$ 45.000
OPEX anual	Energía eléctrica	Consumo del equipo en clase	Supuesto	\$ 60.000
OPEX anual	Nube, API de IA y conectividad	El código no los usa	Verificable	\$ 0
	Total OPEX anual			\$ 405.000
Beneficios brutos anuales	Ahorro de tiempo docente en nivelación individual	1,0 h/semana × 40 semanas × \$ 30.000	PINT2	\$ 1.200.000
Beneficios brutos anuales	Reducción del gasto en papelería didáctica	Fotocopias y cuadernos por aula	PINT2	\$ 600.000
	Total Beneficios brutos anuales			\$ 1.800.000

Nota. PINT2 = Equipo 13 (2026). API = interfaz de programación de aplicaciones.

La Tabla 14 reproduce la plantilla obligatoria de la guía para un aula: beneficio neto de \$ 1.395.000 al año (\$ 116.250 al mes), ROI de 18,9 % y recuperación en 63,4 meses. *Un aula aislada no cumple* los criterios de la guía para software (ROI de al menos 30 % y recuperación de hasta 12 meses), y el resultado se informa sin ajustar los supuestos.

Tabla 14
Plantilla Financiera del Escenario Base (un Aula)

Componente financiero	Descripción	Valor
Inversión inicial (CAPEX)	Desarrollo, hardware, configuración, capacitación y consulta jurídica	\$ 7.370.000
Costos operativos anuales (OPEX)	Mantenimiento, reposición de hardware y energía; sin nube	\$ 405.000
Beneficios brutos anuales	Ahorro de tiempo docente y de papelería	\$ 1.800.000
Beneficio neto anual	Beneficios brutos – OPEX	\$ 1.395.000
ROI calculado (año 1)	(Beneficio neto / CAPEX) × 100	18,9 %
Periodo de retorno (<i>payback</i>)	CAPEX / beneficio neto mensual	63,4 meses

La Tabla 15 y la Figura 10 presentan seis escenarios. Una institución que adopta el sistema en cuatro aulas, con beneficios por aula y un desarrollo que se paga una vez, alcanza un ROI de 71,4 % y recupera la inversión en 16,8 meses: cumple el criterio de ROI y se acerca al de


12 meses sin cumplirlo. La rentabilidad del proyecto proviene, por tanto, de la adopción en varias aulas o instituciones.

Tabla 15

Escenarios frente a los Criterios de la Guía

Escenario	CAPEX	Beneficio neto	ROI año 1	Payback (meses)	ROI $\geq$ 30 %	Payback $\leq$ 12
Conservador (beneficios -25 %)	\$ 7.370.000	\$ 945.000	12,8 %	93,6	No	No
Base (1 aula)	\$ 7.370.000	\$ 1.395.000	18,9 %	63,4	No	No
Optimista (con instrumental evitado)	\$ 7.370.000	\$ 2.395.000	32,5 %	36,9	Sí	No
Institución con 4 aulas	\$ 9.080.000	\$ 6.480.000	71,4 %	16,8	Sí	No
Escala (3 instituciones comparten el desarrollo)	\$ 3.370.000	\$ 1.395.000	41,4 %	29,0	Sí	No
Escala y optimista	\$ 3.370.000	\$ 2.395.000	71,1 %	16,9	Sí	No

Nota. Conservador: beneficios 25 % menores. Optimista: suma el instrumental evitado. Institución: cuatro aulas (supuesto). Escala: el desarrollo se reparte entre tres instituciones de un aula.

Figura 10*Posición Acumulada de Caja por Escenario*

Nota. Posición = $-\text{CAPEX} + \text{mes} \times \text{beneficio neto mensual}$. Los puntos marcan el mes de recuperación.

En un análisis de sensibilidad de $\pm 20\%$ sobre el escenario base, el ROI varía así: las horas de ingeniería de este corte, de $20,2\%$ a $17,8\%$; las horas de nivelación, de $15,7\%$ a $22,2\%$; el gasto de papelería, de $17,3\%$ a $20,6\%$. Ningún cambio de esa magnitud lleva a un aula aislada al umbral de 30% ; las dos variables de beneficio deben medirse en el piloto.

Discusión y Conclusiones

El resultado técnico central es el equilibrio entre sensibilidad y especificidad: el método de la versión 1 reconocía siempre porque respondía siempre, mientras que el descriptor invariante rechaza 92 de cada 100 posturas que no son señal y conserva un acierto del $96,9\%$ con ruido moderado. Frente a la literatura revisada, que adapta la enseñanza con refuerzo profundo, HSK usa reglas explícitas y un MILP que pueden explicarse a un docente y funcionan con pocos

datos por niño, a costa de que sus constantes sean decisiones de diseño. La gobernanza cumple la privacidad por diseño, pero el PIN de adulto, los respaldos, la retención y el borrado completo siguen pendientes. Las limitaciones son una sola calibración de una persona, la ausencia de pruebas con niños, el efecto pedagógico sin medir, beneficios financieros basados en cifras de campo secundarias y una revisión hecha sobre resúmenes.

Se concluye que el prototipo reconoce las ocho señas con un descriptor de 120 componentes en 2,3 ms de cómputo por fotograma y adapta la práctica con un gemelo digital y una planificación MILP verificada contra la enumeración exacta; que la brecha de conectividad de 18,4 puntos justifica el diseño local; y que un aula aislada no alcanza los criterios financieros de la guía (18,9 %; 63,4 meses), mientras que cuatro aulas logran 71,4 % y 16,8 meses. El paso siguiente es un piloto cuasi-experimental de ocho semanas, con grupo de control, que mida discriminación de notas, tiempo de respuesta, retención a cuatro semanas, horas de nivelación y gasto de papelería, con consentimiento de los representantes y cumplimiento de la Ley 1581 de 2012.

Referencias

- Apaydinli, K. (2023). Content analysis of music education studies related to augmented reality technology. *Journal of Educational Technology and Online Learning*, 6(2), 447–481. <https://doi.org/10.31681/jetol.1243501>
- Barroso-Osuna, J., León-Garrido, A., Llorente-Cejudo, C., y Ruiz-Palmero, J. (2024). El impacto de las apps móviles y la carga del trabajo en la Educación Musical universitaria: Un estudio experimental. *Revista de Educación a Distancia (RED)*, 24(80). <https://doi.org/10.6018/red.602301>
- Chuluunsaikhan, T., y Park, S.-H. (2026). Piano keyboard detection algorithm using deep learning. *Multimedia Tools and Applications*, 85(5), Artículo 508. <https://doi.org/10.1007/s11042-026-21667-y>
- Congreso de la República de Colombia. (2012, 17 de octubre). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*. Función Pública. <https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981>
- DAMA International. (2017). *DAMA-DMBOK: Data management body of knowledge* (2.^a ed.). Technics Publications.
- Deng, X., Zhou, Y., Guan, X., y Wang, Y. (2026). An adaptive emotion aware music education system using machine learning for personalized emotional wellbeing enhancement. *Scientific Reports*, 16(1), Artículo 25833. <https://doi.org/10.1038/s41598-026-53749-0>
- Deng, X. (2026). AI-based feedback systems in piano education: Effects on technical accuracy and learner autonomy. *Música Hodie*, 26. <https://doi.org/10.5216/mh.v26.85176>
- Departamento Administrativo Nacional de Estadística. (s. f.). *Proyecciones de población municipal por área, sexo y edad, periodo 2020-2035: Actualización post COVID-19* [Conjunto de datos]. Recuperado el 1 de octubre de 2026, de <https://www.dane.gov.co/files/censo2018/proyecciones-de-poblacion/Municipal/DCD-area-sexo-edad-proypoblacion-Mun-2020-2035-ActPostCOVID-19.xlsx>

- Departamento Administrativo Nacional de Estadística. (2025, 1 de agosto). *Encuesta de Tecnologías de la Información y las Comunicaciones en Hogares (ENTIC Hogares) 2024: Boletín técnico*. <https://www.dane.gov.co/files/operaciones/ENTIC/bol-ENTICHogares-2024.pdf>
- Equipo 13. (2026). *Documento técnico de ingeniería y arquitectura de proyecto: Desarrollo de un sistema inteligente adaptativo mediante visión computacional, gamificación e inteligencia artificial para el aprendizaje de teoría musical infantil en el Departamento de Córdoba 2026* [Manuscrito no publicado, Proyecto Integrador II]. Facultad de Ingeniería Industrial, Universidad Pontificia Bolivariana, Seccional Montería.
- León-Garrido, A., Barroso-Osuna, J. M., y Llorente-Cejudo, M. C. (2024). Diseño y validación de un instrumento de evaluación para apps móviles musicales a través del juicio de expertos. *Aula Abierta*, 53(2), 169–179. <https://doi.org/10.17811/rifie.20620>
- Li, N., y Hong, Z. (2026). Deep reinforcement learning for personalised music learning pathways. *Annals of Data Science*, 13(4), 1013–1032. <https://doi.org/10.1007/s40745-026-00689-1>
- Li, J. (2026). A reinforcement learning-based adaptive evaluation framework for personalized music education. *PeerJ Computer Science*, 12, Artículo e3464. <https://doi.org/10.7717/peerj-cs.3464>
- Li, J. (2026). Deep learning-based personalized learning path planning and optimization model for music education. *Discover Artificial Intelligence*, 6(1), Artículo 434. <https://doi.org/10.1007/s44163-026-01115-4>
- Mazlan, C. A. N., Abdullah, M. H., Sulong, M. A., Abas, A., Ramdan, M. R., Safian, A. R., y Syariff M. Fuad, D. R. (2023). Exploring the integration of bite-sized learning: A scoping review of research in education and related disciplines. *Contemporary Educational Technology*, 15(4), Artículo ep468. <https://doi.org/10.30935/cedtech/13622>
- Ramoneda, P., Suzuki, M., Maezawa, A., y Serra, X. (2026). Difficulty-aware score generation for piano sight-reading. *Expert Systems with Applications*, 321, Artículo 132088. <https://doi.org/10.1016/j.eswa.2026.132088>

[oi.org/10.1016/j.eswa.2026.132088](https://doi.org/10.1016/j.eswa.2026.132088)

- Shi, X. (2026). An affective computing framework for preschool music education using MoE architecture and neural radiance fields. *Discover Artificial Intelligence*, 6(1), Artículo 812. <https://doi.org/10.1007/s44163-026-01858-0>
- Tang, X. (2026). The application of deep reinforcement learning in music teaching interaction. *Discover Computing*, 29(1), Artículo 131. <https://doi.org/10.1007/s10791-026-10022-2>
- Wang, Z. (2026). Music teaching evaluation using multimodal deep reinforcement learning. *Discover Artificial Intelligence*, 6(1), Artículo 151. <https://doi.org/10.1007/s44163-026-00832-0>
- Yi, H., Liu, T., y Lan, G. (2024). The key artificial intelligence technologies in early childhood education: A review. *Artificial Intelligence Review*, 57(1), Artículo 12. <https://doi.org/10.1007/s10462-023-10637-7>
- Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., y Grundmann, M. (2020). *MediaPipe Hands: On-device real-time hand tracking* (arXiv:2006.10214). arXiv. <https://doi.org/10.48550/arXiv.2006.10214>